UNIVERSIDADE DE BRASÍLIA
FACULDADE DE CIENCIAS E TECNOLOGIAS EM ENGENHARIA

INTEGRAÇÃO DOS FUNDAMENTOS DA INTELIGÊNCIA ARTIFICIAL:

UMA ANÁLISE SISTÊMICA DA RACIONALIDADE, EVOLUÇÃO HISTÓRICA E GOVERNANÇA SOCIOTÉCNICA

PEDRO GOMES OLIVEIRA
Matrícula: 211031440

Resenha Crítica Ampliada apresentada como requisito parcial de avaliação na disciplina FGA0221 — Inteligência Artificial (Turma T01), no curso de Engenharia da Universidade de Brasília.

Professor Orientador: Dr. Fabiano Araujo Soares

GAMA, DF
2026

1. INTRODUÇÃO

A Inteligência Artificial (IA) consolidou-se, nas últimas décadas, como uma das principais áreas responsáveis por transformações econômicas, científicas e sociais no mundo contemporâneo. Mais do que um campo específico da ciência da computação ou uma ferramenta utilizada apenas para realizar tarefas determinadas, a IA passou a desenvolver sistemas capazes de tomar decisões, resolver problemas e executar atividades que anteriormente elas dependiam exclusivamente da capacidade humana. Em alguns casos, essas tecnologias já apresentam desempenho superior ao humano em tarefas específicas. Diante desse cenário de rápida evolução, esta resenha crítica ampliada tem como objetivo analisar e contextualizar os principais conceitos, métodos e questões éticas relacionados ao desenvolvimento da Inteligência Artificial. Para isso, o estudo aborda o conceito de agente racional, a evolução histórica da área e os novos desafios éticos, sociais e técnicos decorrentes da crescente utilização dessas tecnologias.

A importância deste estudo está na necessidade de compreender a Inteligência Artificial para além de seus aspectos técnicos e de sua aplicação prática. É necessário também analisar os princípios e os impactos envolvidos no desenvolvimento e na utilização de sistemas inteligentes. A partir da análise de estudos teóricos e de pesquisas realizadas por instituições de referência, como o *One Hundred Year Study on Artificial Intelligence* (AI100) e os relatórios do *Stanford University AI Index* (2021–2025), esta resenha apresenta uma reflexão crítica sobre o desenvolvimento da IA e suas consequências. Nesse contexto, observa-se que as escolhas realizadas no desenvolvimento de algoritmos e sistemas autônomos podem gerar impactos técnicos, éticos e jurídicos. Por esse motivo, torna-se cada vez mais importante estabelecer princípios de governança, regulamentação e avaliação contínua para garantir que o desenvolvimento e o uso da Inteligência Artificial ocorram de maneira responsável, tanto em âmbito nacional quanto internacional.

2. RESUMO DO CONTEÚDO

2.1 O Paradigma da Agência Racional

Um dos principais conceitos da Inteligência Artificial é o de agente inteligente. Segundo Russell e Norvig (2013), um agente é qualquer entidade capaz de perceber o ambiente ao seu redor por meio de sensores e de agir sobre esse ambiente utilizando atuadores. Essa definição representa uma mudança em relação às primeiras propostas da área, que buscavam principalmente reproduzir o pensamento ou o comportamento humano, como apresentado por Alan Turing em seu teste, o teste de turing. Atualmente, o principal objetivo da Inteligência Artificial está relacionado à capacidade de um sistema tomar decisões de forma racional. Nesse contexto, um agente racional é aquele que atua no ambiente buscando alcançar o melhor resultado possível, considerando as informações obtidas por meio de suas percepções e o conhecimento que possui.

A definição do ambiente em que o agente irá atuar pode ser realizada por meio do modelo PEAS, sigla em inglês para Medida de Desempenho (*Performance*), Ambiente (*Environment*), Atuadores (*Actuators*) e Sensores (*Sensors*). De acordo com Russell e Norvig (2013), a identificação desses elementos é uma etapa importante no desenvolvimento de um sistema inteligente. Os ambientes podem apresentar diferentes níveis de complexidade, que podem ser analisados considerando características como observabilidade, determinismo, dinamismo e continuidade. A partir dessas características, diferentes tipos de agentes podem ser desenvolvidos. Eles vão desde agentes simples, que respondem diretamente aos estímulos recebidos, até agentes capazes de trabalhar com objetivos, avaliar diferentes possibilidades e aprender continuamente com as informações obtidas.

2.2 A Evolução Histórica: Da Busca Heurística ao Deep Learning

A história da Inteligência Artificial é marcada por períodos de grande expectativa e desenvolvimento, seguidos por momentos de redução de investimentos e interesse na área, conhecidos como invernos da IA. A primeira fase, frequentemente chamada de *Good Old-Fashioned AI* (GOFAI), concentrou-se no uso de regras lógicas, raciocínio formal e métodos de busca para resolver problemas. Entretanto, algumas limitações técnicas dificultaram o avanço dessas abordagens. Entre elas estava a dificuldade dos *perceptrons* lineares em representar determinadas funções não lineares, problema discutido por Minsky e Papert (1969), além da grande dificuldade de solucionar problemas que apresentavam um número muito

elevado de possibilidades. Essas limitações contribuíram para o primeiro período de redução do interesse e dos investimentos na área.

A Inteligência Artificial voltou a ganhar destaque com o desenvolvimento dos sistemas especialistas, principalmente durante a década de 1980. Esses sistemas utilizavam regras definidas por especialistas humanos para representar conhecimentos e tomar decisões. Apesar dos avanços, essa abordagem apresentava limitações, principalmente por depender de regras previamente estabelecidas e possuir pouca capacidade de adaptação diante de situações novas ou de informações diferentes das previstas. Essas dificuldades contribuíram para o segundo inverno da Inteligência Artificial. A superação dessas limitações ocorreu com o avanço dos métodos de aprendizado de máquina. Conforme apresentado por LeCun, Bengio e Hinton (2015), o desenvolvimento do Aprendizado Profundo (*Deep Learning*) trouxe mudanças importantes para a área ao permitir que redes neurais com várias camadas aprendessem representações de dados complexos. Dessa forma, tornou-se possível identificar padrões e características diretamente a partir de grandes volumes de dados, sem depender exclusivamente de regras definidas manualmente.

Esse avanço também teve grande impacto em problemas tradicionais da computação. Um exemplo é o confronto entre o Deep Blue, desenvolvido pela IBM, e o campeão mundial de xadrez Garry Kasparov. Em 1997, o sistema derrotou Kasparov utilizando principalmente buscas extensivas e funções de avaliação desenvolvidas manualmente (CAMPBELL; HOANE; HSU, 2002). Anos depois, em 2016, o AlphaGo, desenvolvido pela DeepMind, apresentou uma abordagem diferente. O sistema utilizou redes neurais profundas para analisar posições e escolher jogadas, sendo treinado inicialmente com partidas humanas e posteriormente aprimorado por meio de partidas realizadas contra si mesmo (*self-play*). O AlphaGo derrotou o jogador profissional Lee Sedol no jogo de Go, considerado um problema especialmente complexo devido ao número muito elevado de possibilidades de jogadas (SILVER et al., 2016). Esse resultado demonstrou o potencial das técnicas modernas de aprendizado profundo para resolver problemas que apresentavam grandes limitações para os métodos tradicionais.

3. ANÁLISE CRÍTICA

3.1 Tensões Entre as Ambições de Racionalidade e a Complexidade do Mundo Real

A definição de racionalidade apresentada por Russell e Norvig (2013) encontra algumas limitações quando aplicada a ambientes complexos e pouco estruturados do mundo físico e social. O modelo teórico considera que um agente racional deve escolher a ação que apresenta o melhor resultado esperado a partir das informações disponíveis. No entanto, na prática, os sistemas possuem limitações de tempo, processamento e acesso às informações. Em situações muito complexas, torna-se impossível analisar todas as possibilidades existentes antes de tomar uma decisão. Por isso, os sistemas precisam utilizar métodos mais simples, como as heurísticas, para encontrar soluções em um tempo adequado. Embora essas estratégias sejam úteis, elas também podem levar a decisões menos precisas ou diferentes da melhor solução possível.

Essa diferença entre o modelo teórico e a aplicação prática também pode ser observada nas previsões sobre o desenvolvimento da Inteligência Artificial. No primeiro relatório do *One Hundred Year Study* (AI100), Stone et al. (2016) apontaram que, até 2030, o desenvolvimento da IA estaria concentrado principalmente em sistemas especializados, desenvolvidos para tarefas específicas e áreas bem delimitadas. Entretanto, relatórios posteriores, como o estudo de Littman et al. (2021) e os dados apresentados pelo *Stanford University AI Index* (2025), mostram que a evolução da área ocorreu de maneira diferente. O desenvolvimento de modelos de propósito geral e de sistemas multimodais ampliou significativamente as capacidades dos sistemas de IA. Atualmente, esses modelos podem trabalhar com diferentes tipos de informação, como texto, voz e imagens, além de realizar tarefas que antes exigiam sistemas especializados separados.

Essa evolução demonstra uma diferença importante entre as previsões realizadas anteriormente e o desenvolvimento efetivamente observado. A expansão dos chamados modelos fundacionais modificou a trajetória da Inteligência Artificial, que passou de uma forte dependência de sistemas especializados para modelos capazes de atuar em diferentes tipos de tarefas. Dessa forma, observa-se que a evolução tecnológica pode ocorrer de maneira diferente daquela prevista pelos estudos anteriores, principalmente quando surgem novas técnicas, maior capacidade computacional e grandes volumes de dados.

A Tabela 1 apresenta uma síntese das principais diferenças entre o modelo clássico de agentes inteligentes e as características observadas nos sistemas de IA mais recentes.

Dimensão de Análise	Paradigma Teórico Clássico	Evidência Empírica Recente (AI Index / AI100)
Especialização Algorítmica	Sistemas focados em tarefas exclusivas, pautados em heurísticas lógicas rígidas (STONE et al., 2016).	Consolidação de agentes de propósito geral e modelos multimodais integrados (STANFORD UNIVERSITY, 2025).
Transparência e Explicabilidade	Decisões dedutivas amparadas em lógica de primeira ordem ou redes bayesianas normativas e auditáveis (RUSSELL; NORVIG, 2013).	Sistemas de fronteira privados sob arquitetura 'caixa-preta', com baixa transparência de dados e métodos (STANFORD UNIVERSITY, 2024).
Segurança de Agência e Alinhamento	Salvaguardas matemáticas estritas aplicadas na especificação de funções de recompensa e de performance (RUSSELL; NORVIG, 2013).	Alta suscetibilidade a ataques de injeção ('jailbreak') decorrentes de alinhamentos superficiais de segurança (QI et al., 2024).

Tabela 1: Divergências entre Modelagem Clássica e Estado da Arte da IA.

3.2 Fragilidades Metodológicas e Alinhamento Superficial dos Modelos

A análise dos resultados apresentados pelo *Stanford AI Index* (2025) mostra que as capacidades dos sistemas de IA continuam avançando em diversas tarefas. Entretanto, esse avanço técnico não garante, por si só, que os sistemas apresentem um comportamento seguro e adequado em todas as situações. Um dos pontos importantes do debate atual sobre segurança em IA é a existência de limitações nos mecanismos utilizados para alinhar o comportamento dos modelos aos princípios de segurança.

Qi et al. (2024) demonstraram que algumas medidas de segurança presentes em grandes modelos de linguagem podem ser consideradas superficiais. Segundo os autores, determinadas restrições podem ser contornadas quando o modelo é submetido a instruções elaboradas de

maneira específica. Em determinados casos, pequenas alterações na forma como uma solicitação é apresentada podem fazer com que o sistema produza respostas que deveriam ser bloqueadas pelos mecanismos de segurança.

Esse problema demonstra que a implementação de regras de segurança não é suficiente para garantir que um modelo de Inteligência Artificial se comporte de maneira adequada em todas as situações. Se pequenas mudanças nas instruções forem capazes de contornar essas restrições, torna-se necessário desenvolver mecanismos de segurança mais resistentes e realizar avaliações contínuas dos modelos. Portanto, o avanço das capacidades dos sistemas de IA deve ser acompanhado pelo desenvolvimento de métodos capazes de garantir maior segurança, confiabilidade e controle sobre seus resultados.

4. CENÁRIO REGULATÓRIO BRASILEIRO

Ao relacionar os conceitos de agente racional apresentados por Russell e Norvig (2013) e os dados do *Stanford AI Index* (2025) com a realidade brasileira, é possível perceber que o desenvolvimento de sistemas de Inteligência Artificial também está diretamente relacionado às decisões políticas e às regras estabelecidas no país. No Brasil, as discussões sobre o desenvolvimento e o uso responsável da IA estão presentes no Plano Brasileiro de Inteligência Artificial (PBIA 2024–2028), lançado em julho de 2024 sob coordenação do Ministério da Ciência, Tecnologia e Inovação (MCTI). O plano prevê investimentos superiores a R$ 23 bilhões ao longo de quatro anos, destinados principalmente ao desenvolvimento de infraestrutura computacional e ao incentivo à inovação no setor produtivo.

Entre as propostas do PBIA está o desenvolvimento de uma infraestrutura computacional própria, com o objetivo de aumentar a capacidade do Brasil de processar grandes volumes de dados e reduzir sua dependência de empresas estrangeiras de tecnologia e serviços de computação em nuvem. Essa proposta está relacionada aos dados apresentados pelo *Stanford AI Index* (2024), que mostram a forte participação das grandes empresas privadas norte-americanas no desenvolvimento dos modelos de IA mais avançados. Em 2023, por exemplo, empresas do setor industrial desenvolveram 51 modelos de fronteira, enquanto instituições acadêmicas produziram 15. Dessa forma, a busca por uma infraestrutura nacional pode ser entendida como uma estratégia para aumentar a autonomia tecnológica do país e fortalecer o controle sobre os dados e recursos necessários para o desenvolvimento de sistemas de Inteligência Artificial.

A relação entre o conceito de medida de desempenho, presente no modelo PEAS, e a proteção dos direitos dos cidadãos também pode ser observada nas discussões sobre o Projeto de Lei nº 2338 de 2023 onde O projeto propõe regras para o desenvolvimento e o uso de sistemas de Inteligência Artificial, classificando-os de acordo com os possíveis riscos que podem causar à sociedade. A proposta estabelece medidas de controle para sistemas utilizados em áreas consideradas sensíveis, como serviços públicos, concessão de benefícios, análise de crédito e utilização de dados biométricos. Para esses casos, estão previstas medidas como avaliações de impacto e mecanismos de fiscalização e auditoria.

Essas propostas de regulamentação buscam reduzir os riscos associados ao uso de sistemas de IA, especialmente em situações nas quais decisões automatizadas podem afetar diretamente os direitos das pessoas. Essa preocupação também está relacionada ao crescimento dos incidentes envolvendo Inteligência Artificial registrados pelo *AI Incident Database* e apresentados no *Stanford AI Index* (2025). Entre os problemas identificados estão casos de discriminação algorítmica, exposição de informações confidenciais e tentativas de manipulação de sistemas de IA. Dessa forma, o cenário brasileiro demonstra que o desenvolvimento tecnológico da Inteligência Artificial precisa ser acompanhado por medidas de segurança, transparência e responsabilidade, principalmente quando esses sistemas são utilizados em decisões que podem produzir impactos significativos na sociedade.

5. CONCLUSÃO

A evolução da Inteligência Artificial, analisada a partir do conceito de agente racional apresentado por Russell e Norvig (2013) e das evidências observadas nas últimas décadas, demonstra que a área deixou de ser apenas uma ferramenta voltada para tarefas específicas e passou a ocupar um papel mais amplo na sociedade. O desenvolvimento do aprendizado profundo (LECUN; BENGIO; HINTON, 2015) contribuiu para a superação de algumas das limitações que marcaram os períodos anteriores da área e possibilitou o desenvolvimento de sistemas capazes de realizar diferentes tipos de tarefas. Entretanto, esse avanço também trouxe novos desafios relacionados à segurança, à ética, ao funcionamento dos sistemas e à forma como eles são utilizados pela sociedade. Esses problemas não podem ser solucionados apenas por meio da melhoria dos algoritmos e de seus mecanismos de otimização.

Nesse contexto, compreender a Inteligência Artificial também a partir de princípios éticos e das normas existentes é fundamental para reduzir possíveis impactos negativos de seu uso. A utilização de sistemas automatizados em processos de tomada de decisão pode reproduzir ou aumentar desigualdades e formas de discriminação já existentes, além de criar novos riscos relacionados à segurança e à privacidade dos dados. As iniciativas de regulamentação em diferentes países e, no Brasil, propostas como o PBIA 2024–2028 e o Projeto de Lei nº 2338 de 2023 demonstram a preocupação das instituições em estabelecer regras para o desenvolvimento e a utilização responsável dessas tecnologias.

Como possibilidade para estudos futuros, destacam-se dois desafios importantes. O primeiro está relacionado aos impactos ambientais do crescimento da computação necessária para treinar e utilizar grandes modelos de Inteligência Artificial, especialmente em relação ao consumo de energia, água e às emissões de carbono. O segundo está relacionado à disponibilidade de dados produzidos por seres humanos para o treinamento dos modelos. Com o aumento do uso de conteúdos gerados por sistemas de IA, torna-se importante estudar os possíveis efeitos do treinamento de novos modelos utilizando principalmente dados sintéticos e os riscos que isso pode trazer para a qualidade e a diversidade das informações utilizadas no aprendizado.

6 REFERÊNCIAS BIBLIOGRÁFICAS

BRASIL. Congresso Nacional. Senado Federal. **Projeto de Lei nº 2338, de 2023**. Dispõe sobre o uso da Inteligência Artificial. Brasília, DF: Senado Federal, 2023. Disponível em: <https://www25.senado.leg.br/web/atividade/materias/-/materia/157248>. Acesso em: 8 set. 2026.

BRASIL. Ministério da Ciência, Tecnologia e Inovações (MCTI). **Plano Brasileiro de Inteligência Artificial (PBIA 2024-2028)**: Inteligência Artificial para o Bem de Todos. Brasília, DF: MCTI, julho de 2024.

CAMPBELL, Murray; HOANE, Joseph; HSU, Feng-hsiung. Deep Blue. **Artificial Intelligence**, v. 134, n. 1-2, p. 57-83, 2002. DOI: 10.1016/S0004-3702(01)00129-1.

LECUN, Yann; BENGIO, Yoshua; HINTON, Geoffrey. Deep learning. **Nature**, v. 521, n. 7553, p. 436-444, 2015. DOI: 10.1038/nature14539.

LITTMAN, Michael L. et al. **Gathering Strength, Gathering Storms**: The One Hundred Year Study on Artificial Intelligence (AI100) 2021 Study Panel Report. Stanford, CA: Stanford University, setembro de 2021. Disponível em: <http://ai100.stanford.edu/2021-report>. Acesso em: 8 set. 2026.

QI, Xiang et al. Safety Alignment Should Be Made More Than Just a Few Tokens Deep. **arXiv preprint arXiv:2406.05946**, 2024. DOI: 10.48550/arXiv.2406.05946.

RUSSELL, Stuart; NORVIG, Peter. **Inteligência Artificial**: uma abordagem moderna. 3. ed. Rio de Janeiro: Elsevier, 2013. 998 p.

SILVER, David et al. Mastering the game of Go with deep neural networks and tree search. **Nature**, v. 529, n. 7587, p. 484-489, 2016. DOI: 10.1038/nature16961.

STANFORD UNIVERSITY. **The Artificial Intelligence Index Report 2024**. Stanford, CA: Institute for Human-Centered AI (HAI), 2024. Disponível em: <https://aiindex.stanford.edu/report/>. Acesso em: 8 set. 2026.

STANFORD UNIVERSITY. **The Artificial Intelligence Index Report 2025**. Stanford, CA: Institute for Human-Centered AI (HAI), 2025. Disponível em: <https://aiindex.stanford.edu/report/>. Acesso em: 8 set. 2026.

STONE, Peter et al. **Artificial Intelligence and Life in 2030**: One Hundred Year Study on Artificial Intelligence (AI100) 2016 Study Panel Report. Stanford, CA: Stanford University, setembro de 2016. Disponível em: <http://ai100.stanford.edu/2016-report>. Acesso em: 8 set. 2026.